




DOKUMENTACJA PROJEKTU

# KLASYFIKACJA TYPÓW GWIAZD

z wykorzystaniem drzewa decyzyjnego

---

Politechnika Bydgoska im. Jana i Jędrzeja Śniadeckich

Wydział Telekomunikacji, Informatyki i Elektrotechniki

Autorzy Maciej Kwiatkowski  
Mikołaj Gawroński  
Mateusz Machowski

# Spis treści

---

---

1. Cel i zakres projektu

---

2. Charakterystyka zbioru danych

---

3. Eksploracyjna analiza danych

---

4. Przygotowanie danych i metodyka

---

5. Model bazowy

---

6. Strojenie i model finalny

---

7. Interpretacja modelu

---

8. Dyskusja i ograniczenia

---

9. Wnioski końcowe

---

10. Uruchomienie i artefakty

---

# 1. Cel i zakres projektu

Pełny proces budowy klasyfikatora od danych do interpretacji wyniku

Celem projektu jest zbudowanie i ocena modelu drzewa decyzyjnego służącego do klasyfikacji typów gwiazd na podstawie ich właściwości fizycznych oraz termodynamicznych.

Zakres prac obejmuje:

- wczytanie i weryfikację jakości zbioru danych,
- eksploracyjną analizę danych i ocenę rozkładu klas,
- przygotowanie cech numerycznych i kategoriycznych,
- budowę modelu bazowego oraz ocenę na zbiorze testowym,
- 5-krotną walidację krzyżową i strojenie hiperparametrów,
- interpretację struktury drzewa i analizę ważności cech,
- zapis finalnego pipeline'u oraz wyników do plików.



Rysunek 1. Schemat procesu realizacji projektu.

## 2. Charakterystyka zbioru danych

### 2.1 Źródło i rozmiar danych

W projekcie wykorzystano zbiór „Star Dataset” udostępniony w serwisie Kaggle. Plik używany w notebooku ma ścieżkę data/star\_dataset\_6\_classes.csv.

Źródło: [Kaggle – Star Dataset](#)

|                 |                        |           |                          |
|-----------------|------------------------|-----------|--------------------------|
| 240<br>rekordów | 7<br>kolumn źródłowych | 6<br>klas | 0<br>braków i duplikatów |
|-----------------|------------------------|-----------|--------------------------|

### 2.2 Zmienne i klasy


| Kolumna          | Typ        | Znaczenie                          |
|------------------|------------|------------------------------------|
| Temperature (K)  | numeryczna | Temperatura gwiazdy w kelwinach.   |
| Luminosity(L/Lo) | numeryczna | Jasność względem jasności Słońca.  |
| Radius(R/Ro)     | numeryczna | Promień względem promienia Słońca. |

| Kolumna                | Typ                                                                                                                                                                                                                                                                            | Znaczenie                    |
|------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------|
| Absolute magnitude(Mv) | numeryczna                                                                                                                                                                                                                                                                     | Magnitudo absolutne gwiazdy. |
| Star color             | kategoryczna                                                                                                                                                                                                                                                                   | Barwa obserwowanej gwiazdy.  |
| Spectral Class         | kategoryczna                                                                                                                                                                                                                                                                   | Klasa spektralna.            |
| Star type              | docelowa                                                                                                                                                                                                                                                                       | Kod klasy od 0 do 5.         |
| Wartość                | Nazwa klasy                                                                                                                                                                                                                                                                    |                              |
| 0                      | Brown Dwarf                                                                                                                                                                                                                                                                    |                              |
| 1                      | Red Dwarf                                                                                                                                                                                                                                                                      |                              |
| 2                      | White Dwarf                                                                                                                                                                                                                                                                    |                              |
| 3                      | Main Sequence                                                                                                                                                                                                                                                                  |                              |
| 4                      | Supergiant                                                                                                                                                                                                                                                                     |                              |
| 5                      | Hypergiant                                                                                                                                                                                                                                                                     |                              |
|                        | <div><div></div><div><b>Uwaga dotycząca danych</b><br/>W kolumnie Star color występują różne warianty zapisu podobnych wartości (np. „Blue-white”, „Blue White”). W projekcie zachowano wartości źródłowe, a One-Hot Encoding obsługuje je jako odrębne kategorie.</div></div> |                              |

### 3. Eksploracyjna analiza danych

#### 3.1 Rozkład klas


Każda z sześciu klas zawiera po 40 obserwacji. Zbiór jest więc idealnie zbalansowany, co ogranicza ryzyko, że wysoka wartość accuracy będzie wynikała głównie z dominacji jednej klasy.



Rysunek 2. Rozkład liczby obserwacji w poszczególnych klasach.

#### 3.2 Korelacje cech numerycznych

Najsilniejszą zależność ze zmienną docelową wykazuje Absolute magnitude(Mv) (korelacja około -0,96). Dodatkowo zależności widoczne są również dla Luminosity(L/Lo) oraz Radius(R/Ro). Korelację z kodem Star type należy traktować pomocniczo, ponieważ jest to etykieta klasy zapisana liczbowo.



Rysunek 3. Macierz korelacji cech numerycznych.

## 4. Przygotowanie danych i metodyka

### 4.1 Podział na zbiór treningowy i testowy

Kolumna `Star_name` została wykorzystana wyłącznie do czytelnego opisu klas i nie była przekazywana do modelu, co zapobiega wyciekowi informacji. Dane podzielono w proporcji 75/25 z parametrem `stratify=y`.

| Zbiór      | Liczba próbek | Udział | Próbek na klasę |
|------------|---------------|--------|-----------------|
| Treningowy | 180           | 75%    | 30              |
| Testowy    | 60            | 25%    | 10              |

### 4.2 Preprocessing i Pipeline

Cechy kategoryczne `Star color` i `Spectral Class` zakodowano metodą One-Hot Encoding z obsługą nieznanymi kategoriami. Cechy numeryczne przekazano bez zmian. `ColumnTransformer` oraz `DecisionTreeClassifier` połączono w jeden Pipeline, dzięki czemu dokładnie ten sam preprocessing jest stosowany podczas uczenia i predykcji.

```
preprocessor = ColumnTransformer([
    ('cat', OneHotEncoder(handle_unknown='ignore'), categorical_features),
    ('num', 'passthrough', numerical_features)
])

model = Pipeline([
    ('preprocessor', preprocessor),
    ('classifier', DecisionTreeClassifier(random_state=42))
])
```


### 4.3 Metryki oceny

Do oceny wykorzystano `accuracy`, raport klasyfikacji (`precision`, `recall` i `F1-score`), macierz pomyłek oraz 5-krotną walidację krzyżową. Dodatkowo porównano średnią i odchylenie standardowe wyników CV.

## 5. Model bazowy

Model bazowy stanowił DecisionTreeClassifier z domyślnymi parametrami oraz random\_state=42. Na 60 próbkach testowych model poprawnie sklasyfikował każdą obserwację.

|                               |                                 |                               |                                      |
|-------------------------------|---------------------------------|-------------------------------|--------------------------------------|
| <b>1,000</b><br>accuracy test | <b>1,000</b><br>CV - cały zbiór | <b>0,000</b><br>odchylenie CV | <b>60/60</b><br>poprawnych predykcji |
|-------------------------------|---------------------------------|-------------------------------|--------------------------------------|



Rysunek 4. Macierz pomyłek modelu bazowego.

Wszystkie wartości znajdują się na przekątnej macierzy. Dla każdej klasy precision, recall oraz F1-score wynoszą 1,00, co oznacza brak zarówno fałszywie dodatnich, jak i fałszywie ujemnych klasyfikacji w zbiorze testowym.

## 6. Strojenie hiperparametrów i model finalny

### 6.1 Przestrzeń przeszukiwania

Do strojenia wykorzystano GridSearchCV. Testowano kryterium podziału, maksymalną głębokość drzewa oraz minimalną liczbę próbek wymaganą do podziału węzła i utworzenia liścia.


| Hiperparametr     | Sprawdzone wartości |
|-------------------|---------------------|
| criterion         | gini, entropy       |
| max_depth         | 2, 3, 4, 5, None    |
| min_samples_split | 2, 4, 6, 8          |
| min_samples_leaf  | 1, 2, 3, 4          |

### 6.2 Najlepsza konfiguracja


| Parametr          | Wartość |
|-------------------|---------|
| criterion         | gini    |
| max_depth         | 4       |
| min_samples_leaf  | 1       |
| min_samples_split | 2       |

|                               |                               |                               |                                      |
|-------------------------------|-------------------------------|-------------------------------|--------------------------------------|
| <b>1,000</b><br>accuracy test | <b>0,994</b><br>CV GridSearch | <b>0,011</b><br>odchylenie CV | <b>60/60</b><br>poprawnych predykcji |
|-------------------------------|-------------------------------|-------------------------------|--------------------------------------|





Rysunek 5. Macierz pomyłek modelu po strojeniu hiperparametrów.



Rysunek 6. Zestawienie accuracy testowego i wyników walidacji zapisanych w notebooku.

### Wniosek ze strojenia

Strojenie nie poprawiło accuracy testowego. Oba drzewa mają tę samą złożoność (głębokość 4, 6 liści i 11 węzłów). Wynik CV = 0,994 pochodzi z GridSearchCV na zbiorze treningowym, a CV = 1,000 dla modelu bazowego - z walidacji na całym zbiorze, dlatego wartości nie są bezpośrednio porównywalne.

## 7. Interpretacja modelu

---

Wizualizacja struktury drzewa oraz analiza ważności cech

### 7.1 Fragment drzewa decyzyjnego


Wizualizację ograniczono do głębokości trzech poziomów, aby zachować czytelność. Każdy węzeł zawiera warunek podziału, miarę nieczystości, liczbę próbek i dominującą klasę.

|                                 |                                  |                                 |                              |
|---------------------------------|----------------------------------|---------------------------------|------------------------------|
| <b>warunek</b><br>próg podziału | <b>gini</b><br>nieczystość węzła | <b>samples</b><br>liczba próbek | <b>value</b><br>rozkład klas |
|---------------------------------|----------------------------------|---------------------------------|------------------------------|

#### Zasada odczytu

Dla spełnionego warunku przechodzimy lewą gałęzią, a dla niespełnionego – prawą. Proces powtarza się aż do osiągnięcia liścia z przewidywaną klasą.

# Wizualizacja drzewa decyzyjnego - max\_depth=3




Rysunek 7. Uproszczona wizualizacja finalnego drzewa decyzyjnego (max\_depth = 3).

## 7.2 Ważność cech

Finalne drzewo wykorzystuje trzy cechy o niezerowej ważności. Pozostałe zmienne nie były potrzebne do wykonania końcowych podziałów w tym konkretnym zbiorze.

| Pozycja | Cecha                  | Ważność |
|---------|------------------------|---------|
| 1       | Absolute magnitude(Mv) | 0,40    |
| 2       | Radius(R/Ro)           | 0,40    |
| 3       | Luminosity(L/Lo)       | 0,20    |



Rysunek 8. Ważność cech w finalnym modelu.

## 8. Dyskusja wyników i ograniczenia

---

### 8.1 Interpretacja rezultatu 100%

Perfekcyjny wynik na zbiorze testowym jest spójny z wynikami walidacji krzyżowej i macierzami pomyłek. Nie powinien być jednak interpretowany jako gwarancja bezbłędnego działania modelu dla dowolnych danych astronomicznych.

### 8.2 Najważniejsze ograniczenia

- niewielka liczba obserwacji (240 rekordów),
- idealnie zbalansowane klasy i brak wartości brakujących,
- bardzo wysoka separowalność klas przez kilka cech fizycznych,
- dydaktyczny charakter zbioru danych,
- brak niezależnego zewnętrznego zbioru walidacyjnego,
- niespójne warianty tekstowe w kolumnie Star color.

### 8.3 Możliwe kierunki rozwoju

- walidacja na większym i bardziej zróżnicowanym zbiorze,
- ujednolicenie kategorii koloru gwiazd przed kodowaniem,
- porównanie z Random Forest, Gradient Boosting i SVM,
- analiza stabilności ważności cech przy różnych losowych podziałach,
- zastosowanie dodatkowych metryk i kalibracji prawdopodobieństw.

## 9. Wnioski końcowe

---

1. Drzewo decyzyjne skutecznie rozdzieliło wszystkie sześć klas gwiazd w dostępnym zbiorze.
2. Model bazowy osiągnął accuracy testowe 1,00 oraz średnią CV 1,00.
3. GridSearchCV wybrał `max_depth = 4`; finalne drzewo zachowało accuracy 1,00 i miało taką samą złożoność jak model bazowy (głębokość 4, 6 liści, 11 węzłów).
4. Najważniejsze cechy to magnitudo absolutne, promień i jasność gwiazdy.
5. Wynik powinien być odnoszony wyłącznie do charakterystyki analizowanego zbioru danych.

## 10. Uruchomienie projektu i zapisane artefakty

### 10.1 Struktura projektu

```
DD-projekt/  
├── DD_PROJ.ipynb  
├── DOKUMENTACJA_PROJEKTU.md  
├── requirements.txt  
├── data/  
│   └── star_dataset_6_classes.csv  
└── outputs/  
    ├── best_decision_tree_model.pkl  
    ├── decision_tree_visualization.png  
    ├── feature_importance.csv  
    └── model_results.csv
```

### 10.2 Wymagania

Projekt wymaga Pythona oraz bibliotek: pandas, matplotlib, seaborn, scikit-learn i joblib. Zależności można zainstalować poleceniem:

```
pip install -r requirements.txt
```

### 10.3 Sposób uruchomienia

- Otwórz plik DD\_PROJ.ipynb w Jupyter Notebook, JupyterLab, PyCharm lub Google Colab.
- Upewnij się, że plik danych znajduje się w katalogu data/.
- Uruchom wszystkie komórki notebooka od góry do dołu.
- Zweryfikuj pliki utworzone w katalogu outputs/.

### 10.4 Artefakty wyjściowe

| Plik                            | Opis                                                            |
|---------------------------------|-----------------------------------------------------------------|
| model_results.csv               | Porównanie modelu bazowego i modelu po strojeniu.               |
| feature_importance.csv          | Tabela ważności wszystkich cech po preprocessingu.              |
| best_decision_tree_model.pkl    | Zapisany pipeline z preprocessingiem i finalnym klasyfikatorem. |
| decision_tree_visualization.png | Wizualizacja drzewa decyzyjnego w wysokiej rozdzielczości.      |